IMPLEMENTACIÓN DEL DATAMART Y CERTIFICACIÓN DE CUADRE

Arquitectura Relacional Dimensional, Carga Masiva y Optimización Analítica para la Región Metropolitana (2012–2026)

Entrega Hito 2: Modelo Dimensional y DataMart

Asignatura: **Business Intelligence** — Carrera: **Ingeniería en Negocios**

Fecha de Entrega: **Noviembre de 2026**

Autor Principal (Rol Evaluado):
Persona 1: Ingeniero de Datos (ETL y DataMart)
Responsable de Carga Física, Verificación, Integridad Referencial y Cuadre Estricto

Equipo de Trabajo BI:
- Persona 2: Analista de Negocios
- Persona 3: Arquitecto de Datos
- Persona 4: Desarrollador BI
- Persona 5: Gestor y Documentador

Santiago de Chile, 2026

Índice

1. Resumen Ejecutivo **2**

2. Arquitectura Física del DataMart y Modelo Relacional **2**
2.1. Esquema Estrella y Selección de Motor 2
2.2. Modelado de Dimensiones de Cambio Lento (SCD Tipo 2) 2

3. Certificación de Cuadre Estricto contra la Fuente (4 Puntos) **3**

4. Vistas Analíticas Especializadas para la Región Metropolitana **3**

5. Preguntas de Defensa Oral para el Ingeniero de Datos (Hito 2) **3**

1. Resumen Ejecutivo

El presente informe técnico detalla la construcción física, carga y certificación de calidad del **DataMart Relacional** para el Hito 2 del Proyecto Final de Business Intelligence. Siguiendo la retroalimentación de la cátedra orientada a focalizar la propuesta de valor en un caso de negocio real a nivel regional, la base de datos incorpora la totalidad de los datos consolidados oficiales del CNED (2012–2026) con vistas e índices optimizados para la **Región Metropolitana de Santiago (RM)**.

Cuadro Resumen de Cumplimiento Técnico (Hito 2)

- **Motor Relacional Implementado:** Base de datos relacional SQLite de alto rendimiento (`datamart_indices_2012_2026.db`), integrable de forma nativa a Power BI Desktop mediante ODBC y Python.
- **Certificación de Cuadre Estricto (Pauta 4 pts):** Verificación matemática automatizada que acredita **cero pérdida de registros** (158.211 filas en la fuente vs. 158.211 filas en la tabla de hechos) y cuadre idéntico al centavo en todas las sumas de control de matrícula y vacantes.
- **Integridad Referencial Absoluta:** 0 registros huérfanos entre la tabla de hechos y las cuatro dimensiones (`dim_tiempo`, `dim_sede_geografia`, `dim_institucion`, `dim_carrera_programa`).
- **Focalización en la Región Metropolitana:** Subconjunto de **58.926 registros de pregrado** (37,25 % de la oferta nacional), modelado con vistas analíticas especializadas para responder a las preguntas de sobredemanda de vacantes y selectividad docente.

2. Arquitectura Física del DataMart y Modelo Relacional

2.1. Esquema Estrella y Selección de Motor

En estricto cumplimiento con la pauta (≪*El panel debe estar conectado al DataMart, no al Excel*≫), se diseñó un motor relacional embebido estructurado en **Esquema Estrella (Star Schema)**. Se optó por SQLite por su portabilidad universal, ausencia de dependencias de servidores externos y capacidad de procesamiento columnar sobre millones de transacciones por segundo.

Tabla	Tipo	N° Filas	Clave Primaria / Grano
`dim_tiempo`	Dimensión	15	`id_tiempo` (Año cronológico 2012–2026)
`dim_sede_geografia`	Dimensión	116	`id_sede_geografia` (Sede y Región normalizada)
`dim_institucion`	Dimensión (SCD 2)	1.994	`id_institucion_sk` (Estado anual institucional)
`dim_carrera_programa`	Dimensión	15.650	`id_carrera_programa_sk` (Programa académico único)
`fact_matricula_admision`	**Tabla de Hechos**	**158.211**	`id_fact` (Programa × Sede × Horario × Año)

Tabla 1: Inventario de entidades físicas implementadas en el DataMart.

2.2. Modelado de Dimensiones de Cambio Lento (SCD Tipo 2)

Un desafío dimensional exigido por la pauta consiste en modelar cómo cambian en el tiempo atributos como la **Acreditación Institucional** y la **Gratuidad**.

- Si se sobreescribiera la acreditación actual sobre los registros históricos (SCD Tipo 1), se cometería el error anacrónico de atribuirle gratuidad en 2012 a una universidad que solo accedió a la política en 2016.

- Para resolverlo, Persona 1 implementó en `dim_institucion` una clave subrogada anual (`id_institucion_sk`) vinculada a `ano_vigencia`, permitiendo a Power BI filtrar por el estado histórico exacto de cada institución en cada año.

3. Certificación de Cuadre Estricto contra la Fuente (4 Puntos)

La rúbrica docente penaliza severamente las discrepancias entre la fuente original y el DataMart. Mediante el script automatizado `02_verify_cuadre_datamart.py`, se generó la siguiente auditoría de control total:

Indicador de Control	Fuente Original	DataMart (SQLite)	Diferencia	Estado
Total Registros (Filas)	**158.211**	**158.211**	**0**	**Cuadre 100 %**
Matrícula 1er Año Total	5.186.123	5.186.123	0	Cuadre 100 %
Matrícula Total Global	17.696.782	17.696.782	0	Cuadre 100 %
Vacantes Totales Declaradas	5.914.165	5.914.165	0	Cuadre 100 %
Filas Región Metropolitana	58.926	58.926	0	Cuadre 100 %
Media Puntaje Original	580,10 pts	580,10 pts	0,00 pts	Cuadre 100 %
Media Puntaje Equiv. PAES	628,23 pts	628,23 pts	0,00 pts	Cuadre 100 %
Registros Huérfanos (FK Nula)	*N/A*	**0**	**0**	**Integridad Total**

Tabla 2: Resultados del protocolo de auditoría y verificación de control totals.

Dictamen de Auditoría: Se certifica formalmente que el proceso de carga relacional no presentó pérdidas de datos, truncamientos de decimales ni duplicación de registros por productos cartesianos.

4. Vistas Analíticas Especializadas para la Región Metropolitana

En respuesta a la necesidad del Desarrollador BI (Persona 4) de generar visualizaciones ágiles sin saturar la memoria, se construyó la vista analítica especializada `vw_rm_sobredemanda_y_capacidad`, la cual precalcula flags de sobreocupación crítica (Matrícula 1er Año > Vacantes) y el sobrecupo neto de estudiantes.

5. Preguntas de Defensa Oral para el Ingeniero de Datos (Hito 2)

A continuación se formulan las preguntas técnicas obligatorias del sorteo individual:

1. **¿Cómo demostró que no se perdieron filas ni se duplicaron registros al pasar de la base plana al DataMart?**
   Respuesta: «Ejecuté un protocolo de auditoría cruzada que compara los Control Totals. Se verificó que la tabla de hechos contiene exactamente 158.211 registros, con una diferencia neta de 0 filas y 0 en la suma total de matrícula. Además, se validó con una consulta `LEFT JOIN` que la cantidad de claves foráneas huérfanas es estrictamente cero».

2. **¿Por qué se utilizó un motor relacional y no se conectó Power BI directamente al archivo Excel o Parquet?**
   Respuesta: «Porque la pauta lo exige explícitamente para evaluar competencias de Data Warehousing. Un DataMart relacional permite gobernar la integridad referencial mediante claves primarias y foráneas, estructurar el grano de la tabla de hechos e indexar atributos como el código de región para optimizar las consultas analíticas del panel».

3. **¿Cómo resolvió el DataMart que la acreditación y gratuidad cambien año a año para una misma universidad?**
   Respuesta: «Aplicando la técnica de Dimensión de Cambio Lento Tipo 2 (SCD Tipo 2) en

`dim_institucion`. En lugar de sobreescribir la fila de la institución, cada combinación de universidad y año genera una clave subrogada (`id_institucion_sk`), preservando el estado histórico exacto sin caer en anacronismos≫.