HITO 2: MODELO DIMENSIONAL Y DATAMART (10 PUNTOS GRUPALES)

Guía Maestra de Estudio y Defensa Oral — Hito 2

Proyecto Final de Business Intelligence (2012–2026) | Preparación Ejecutiva para la Presentación de Mañana

Proyecto Final de Business Intelligence (2012–2026) | Región Metropolitana

Documento para Preparación de la Presentación y Defensa de Mañana

Elaborado por: Persona 5 (Gestor de Proyecto y Calidad) — Válido para todo el equipo

Fecha: Noviembre de 2026

🎯 ¿De qué se trata esta Guía?

Esta guía está diseñada para que **cualquier integrante del equipo (del 1 al 5)** pueda pararse mañana frente al profesor y la clase, y explicar con total seguridad, claridad gerencial y **sin enredarse en tecnicismos innecesarios**:

1. ¿En qué avanzamos respecto al Hito 1 y por qué cambiamos el rumbo?
2. ¿Qué es exactamente lo que construimos en este Hito 2?
3. ¿Por qué tomamos cada decisión de diseño (Esquema Estrella, grano, medidas, SCD2, SQLite)?
4. ¿Cómo responder con éxito a las preguntas típicas del profesor?

🧭 1. El Gran Salto: ¿En qué avanzamos respecto al Hito 1?

Dimensión	En el Hito 1 teníamos...	En el Hito 2 logramos...	¿Por qué se hizo el cambio? (Feedback del Profe)
Enfoque Geográfico	Intentábamos analizar **todo Chile (16 regiones)** a nivel nacional.	Nos focalizamos estratégicamente en la **Región Metropolitana (RM)**.	El profesor nos dijo que abarcar todo Chile era muy disperso e impedía tomar decisiones reales. En la RM se concentra el **52% de la matrícula nacional** y están todas las universidades, IP y CFT.
Problema de Negocio	Hablábamos de "*equidad territorial*" de forma abstracta.	Abordamos el problema concreto de **Capacidad de Laboratorios, Sobredemanda de Vacantes y Selectividad**.	Resolvimos el caso práctico que dio el profesor en clases: entender qué le pasa a una universidad cuando sube de 120 a 140 alumnos.
Estructura de Datos	Teníamos una **tabla plana gigante** en archivos limpios (158.211 filas y 59 columnas).	Construimos una **base de datos relacional (DataMart en SQLite)** con un **Esquema Estrella formal**.	Para hacer analítica ágil y profesional en Power BI, no se puede trabajar con una sábana plana de Excel; se necesita un modelo dimensional optimizado.
Gobernanza del Tiempo	Mezclábamos atributos institucionales sin considerar su fecha.	Implementamos **SCD Tipo 2 (Slowly Changing Dimensions)** para rastrear cambios año a año.	La gratuidad y la acreditación cambian en el tiempo. Si no se maneja el tiempo, se falsea la historia (ej. decir que en 2012 había gratuidad).
Conexión a Power BI	Bocetos teóricos de visualización.	**Conexión directa y certificada** desde Power BI Desktop hacia el DataMart SQLite (sin Excel).	La pauta exige textualmente: «*Conectado al DataMart, no a Excel*». El tiempo de respuesta es instantáneo (< 25 milisegundos).

🏫 2. El Problema de Negocio: El Ejemplo de los 120 a 140 Estudiantes

> ***Pregunta típica del profesor:*** *«¿Cuál es el dolor real que resuelve su proyecto de BI? ¿Por qué les importa la sobredemanda?»*

¿Cómo explicarlo con tus palabras de forma brillante?

"Profesor, el proyecto resuelve cómo las instituciones de educación superior de la Región Metropolitana gestionan su capacidad física y su selectividad ante aumentos imprevistos de postulantes.

*Tal como usted nos explicó en clases, pasar de **120 a 140 matriculados** en una carrera como Ingeniería o Informática parece un aumento menor de solo 20 alumnos, pero para la universidad representa un **terremoto operativo y financiero**:*

1. **Los laboratorios físicos tienen tope (30 a 40 puestos):**

Con 120 alumnos se llenan de forma perfecta 3 o 4 secciones completas. Con **140 alumnos (+20)**, esos 20 alumnos no caben físicamente en las salas de computación.

1. **Dispara los costos fijos:**

La facultad está obligada a abrir un paralelo nuevo completo, contratar nuevos profesores jornada o por hora, y rearmar todo el horario docente para solo 20 personas.

1. **El riesgo de deserción y caída de puntajes:**

Para llenar esas 20 vacantes extras, la universidad muchas veces baja el puntaje de corte. En carreras duras con ramos filtro como Cálculo o Programación, aceptar alumnos con menor preparación aumenta drásticamente la tasa de reprobación en primer año. El alumno reprueba, se desmotiva, deserta en segundo año, y la universidad pierde el arancel o la gratuidad de los años siguientes, quedándose además con la estructura de costos fijos inflada.

Nuestro panel en Power BI le permite a un decano o vicerrector ver exactamente qué carreras en la RM están sobreocupando vacantes, cómo reaccionaron sus puntajes de corte y si la infraestructura da abasto."

🌟 3. ¿Qué se hizo en este Hito 2? (Los 5 Pilares del Éxito)

Pilar 1: El Modelo Dimensional (Esquema Estrella)

- **¿Qué es un Esquema Estrella?**

Es un diseño donde al centro tenemos una **Tabla de Hechos** (con los números, medidas y transacciones) rodeada de **Tablas de Dimensiones** (que contienen el contexto: quién, cuándo, dónde y qué).

- **Nuestra Tabla Central de Hechos:** `fact_matricula_admision` (guarda los 158.211 registros históricos y sus métricas).
- **Nuestras 5 Dimensiones:**

1. `dim_tiempo`: Los 15 años (2012–2026), identificando si fue época PSU, PDT o PAES, y si hubo pandemia.
2. `dim_sede_geografia`: Las 116 sedes con su región oficial (SUBDERE), macro-zona y si pertenece a la Región Metropolitana.
3. `dim_institucion`: Las 259 universidades, IP y CFT, con su acreditación, gratuidad y tipo (CRUCH, privada, estatal).
4. `dim_carrera_programa`: Los planes de estudio, con sus 11 áreas de conocimiento (Tecnología, Salud, etc.) y jornada (Diurno/Vespertino).
5. `dim_poblacion_rm` (Fuente Externa INE): Proyecciones de población juvenil de 18 a 24 años en Santiago para medir la absorción de cupos.

Pilar 2: ¿Qué es el "Grano" de la Tabla de Hechos?

> ***Pregunta típica del profesor:*** *«¿Cuál es el grano de su tabla de hechos?»*

- **Respuesta en simple:**

"El grano es el nivel de detalle de cada fila. En nuestro modelo, ***cada fila representa una oferta académica específica de una carrera, en una sede física determinada, en una jornada determinada (diurna o vespertina) y en un año cronológico determinado ante el CNED****."*

- **¿Por qué este grano y no uno más agregado?**

Porque en una misma sede, una universidad puede tener la carrera de Ingeniería Civil en plan diurno regular (con corte PAES) y en plan especial para trabajadores (ingreso directo sin prueba). Si las promediáramos o colapsáramos, destruiríamos los puntajes de corte y perderíamos registros. Este grano nos permite guardar las **158.211 ofertas exactas con cero pérdidas**.

Pilar 3: La Aditividad de las Medidas (¿Por qué no se suman los puntajes?)

> ***Pregunta típica del profesor:*** *«¿Por qué dicen que la matrícula es aditiva y los puntajes son no aditivos? ¿Cómo lo resolvieron en DAX?»*

1. **Matrícula y Vacantes son Totalmente Aditivas:**

Porque son **conteos físicos de personas y cupos**. Si sumo la matrícula de primer año de 3 sedes, el resultado es la cantidad real de alumnos. En DAX y SQL se usa simplemente `SUM()`.

1. **Los Puntajes PAES/PSU son Estrictamente No Aditivos:**

- **El absurdo de sumarlos:** Si sumas los puntajes de 10 carreras obtienes 7.000 puntos. ¡Eso no existe! La escala PAES va de 100 a 1.000.
- **La trampa del promedio simple (`AVERAGE`):** Si una carrera masiva de Medicina tiene 200 alumnos con 850 puntos, y una carrera chica tiene 5 alumnos con 500 puntos, el promedio simple diría $\frac{850 + 500}{2} = 675$ puntos. ¡Falso! Casi todos los alumnos tienen 850 puntos.
- **Nuestra solución técnica:** En Power BI programamos en DAX un **Promedio Ponderado por Matrícula** usando `SUMX` y `DIVIDE` :

$$\bar{X}_{\text{PAES Ponderado}} = \frac{\sum (\text{Puntaje} \times \text{Matrícula 1er Año})}{\sum \text{Matrícula 1er Año}}$$

1. **Las Tasas (como Ocupación de Vacantes) son Semi-aditivas:**

A nivel de fila atómica son un porcentaje ($\text{Matrícula} / \text{Vacantes}$), pero a nivel agregado no se promedian; se calcula la suma total de matriculados dividida por la suma total de vacantes del filtro seleccionado.

Pilar 4: El Cambio en el Tiempo con SCD Tipo 2 (Acreditación y Gratuidad)

> ***Pregunta típica del profesor:*** *«La acreditación y la gratuidad cambian en el tiempo. ¿Cómo las modelaron y por qué no usaron SCD Tipo 1?»*

- **El Problema:**

La gratuidad nació en **2016**. Si una universidad se adscribió a gratuidad en 2016, entre 2012 y 2015 NO tenía gratuidad. Lo mismo con la acreditación: una universidad puede haber estado no acreditada en 2013 y lograr 5 años en 2020.

- **Por qué rechazamos SCD Tipo 1 (Sobreescritura):**

Porque el SCD Tipo 1 sobreescribe los datos viejos con el valor actual. Si usáramos SCD Tipo 1, el modelo le pondría "*Con Gratuidad*" a los alumnos de 2012, lo cual es una mentira histórica que arruinaría cualquier informe de analítica.

- **Nuestra Solución (SCD Tipo 2 con Fotografía Anual):**

En la tabla `dim_institucion` , cada institución tiene una fila por cada año con una clave única (`id_institucion_sk`) y su `ano_vigencia` . Hay **1.994 fotografías históricas** para 259 instituciones. Así, cuando el usuario filtra el año 2013, la tabla de hechos se conecta con la foto exacta de la universidad en 2013 (sin gratuidad), y cuando filtra 2024, se conecta con la foto de 2024 (con gratuidad). **Preservamos el 100% de la verdad histórica**.

Pilar 5: El DataMart Físico y el Cuadre Matemático al 100%

> ***Pregunta típica del profesor:*** *«¿Dónde está su base de datos y cómo me demuestran que no se perdió ningún dato?»*

- **Motor Utilizado:** Construimos un DataMart relacional físico en **SQLite** (`datamart_indices_2012_2026.db` , 25.3 MB), 100% estándar SQL ANSI, rápido y portátil.
- **La Certificación de Cuadre (Cero Pérdidas, Cero Duplicados):**
- Filas en la fuente limpia consolidada: **158.211 filas**.
- Filas en la tabla de hechos del DataMart: **158.211 filas**.
- **Diferencia Neta: 0 filas (Exactitud absoluta)**.
- Matrícula 1er Año Total: **5.186.123 alumnos** (coincidencia al dígito).
- Matrícula Total Global: **17.696.782 alumnos** (coincidencia al dígito).
- Vacantes Declaradas: **5.914.165 cupos** (coincidencia al dígito).

- Subconjunto Región Metropolitana: **58.926 ofertas académicas**.
- **Registros Huérfanos en Claves Foráneas: 0 huérfanos** (100% de integridad referencial).

👥 4. ¿Qué hizo cada integrante en el equipo? (Para defender en grupo)

Si el profesor pregunta por la división de trabajo:

1. **Persona 1 (Ingeniero de Datos):**

Construyó el pipeline de carga masiva en Python hacia SQLite, creó las vistas analíticas de la RM y programó el script de auditoría que certificó el cuadre de las 158.211 filas.

1. **Persona 2 (Analista de Negocios):**

Rediseñó el Canvas BI de 10 bloques para la RM, redactó las 3 preguntas de negocio (sobredemanda, selectividad y absorción demográfica) y preparó los datos externos de INE y SIES.

1. **Persona 3 (Arquitecto de Datos - Angel Pino):**

Diseñó el Esquema Estrella, declaró el grano de la tabla de hechos, redactó los scripts DDL (`CREATE TABLE`) con claves primarias y foráneas, y generó los diagramas vectoriales.

1. **Persona 4 (Desarrollador BI - Joaquin Aguilera):**

Configuró la conexión directa Power BI $\rightarrow$ DataMart SQLite (sin Excel), modeló las 4 jerarquías de navegación (Geográfica, Institucional, Académica y Temporal) y probó las medidas base en DAX con latencias menores a 25 ms.

1. **Persona 5 (Gestor de Proyecto y Calidad - ¡Tú!):**

Gobernó la metodología dimensional, fundamentó técnicamente la aditividad de medidas y la estrategia SCD Tipo 2, compiló el informe consolidado en LaTeX/Markdown y auditó la matriz de la rúbrica asegurando los **10 / 10 puntos**.

🎯 5. Simulador de Preguntas y Respuestas para la Presentación de Mañana

Pregunta 1: "*¿Por qué cambiaron a la Región Metropolitana si en el Hito 1 presentaron todo Chile?*"

> ***Tu Respuesta:***

> *"Porque tras su feedback comprendimos que intentar abarcar todo Chile diluía la capacidad de tomar decisiones gerenciales reales. La Región Metropolitana concentra el 52% de la matrícula nacional, reúne todas las tipologías institucionales (CRUCH, privadas, IP y CFT) y es donde la saturación de vacantes y la capacidad de laboratorios se vive con mayor crudeza operativa."*

Pregunta 2: "*¿Por qué SQLite y no cargar el archivo plano directo a Power BI?*"

> ***Tu Respuesta:***

> *"La pauta exige explícitamente estar 'Conectado al DataMart, no a Excel'. En analítica corporativa, cargar archivos planos genera duplicidades, no permite validar claves foráneas y sobrecarga el refresco. Al crear un DataMart relacional en SQLite con claves primarias, claves foráneas e índices analíticos, garantizamos integridad referencial (0 huérfanos) y consultas ultrarrápidas (< 25 ms) para Power BI."*

Pregunta 3: *"¿Qué pasa con los puntajes de los Institutos Profesionales y CFT que no exigen PAES?"*

> ***Tu Respuesta:***

> *"En el Hito 1 descubrimos que los puntajes tienen cerca de un 80% de nulos porque los CFT e IP, por ley y misión de inclusión, operan con ingreso directo. En nuestro modelo dimensional, esos nulos se respetan rigurosamente como* `NULL` *(jamás reemplazados por cero) y se identifican mediante el flag de negocio* `flag_exige_prueba_admision = 0`*. Nuestras medidas DAX de puntajes filtran automáticamente este flag, evitando distorsionar los análisis universitarios."*

Pregunta 4: *"¿Cómo se conecta Power BI al archivo SQLite?"*

> ***Tu Respuesta:***

> *"Power BI se conecta de forma directa mediante un script de ingestión optimizado en Python/ODBC que lee las tablas dimensionales y de hechos de* `datamart_indices_2012_2026.db` *y las carga en la memoria columnar VertiPaq en Import Mode, resolviendo las consultas agregadas en menos de 10 milisegundos."*

Pregunta 5: *"¿Por qué no crearon una tabla para Región y otra para Comuna (Copo de Nieve)?"*

> ***Tu Respuesta:***

> *"Siguiendo las mejores prácticas de Ralph Kimball para esquemas estrella en Power BI, desnormalizamos la geografía dentro de* `dim_sede_geografia`*. Crear tablas copo de nieve para región y comuna obligaría al motor VertiPaq a realizar saltos adicionales de relaciones (Snowflaking), lo que ralentiza el rendimiento sin aportar ningún valor analítico."*

📋 6. Acordeón de Cifras Clave (Para tener en la mente)

- **Total de Filas del DataMart:** `158.211` filas (2012–2026).
- **Filas de la Región Metropolitana:** `58.926` ofertas (37,25% de la oferta nacional).
- **Matrícula de Primer Año Acumulada:** `5.186.123` alumnos.
- **Vacantes Totales Declaradas:** `5.914.165` cupos.
- **Matrícula Global Consolidada:** `17.696.782` alumnos.
- **Instituciones Únicas:** `259` casas de estudio.
- **Fotografías Históricas SCD Tipo 2:** `1.994` registros en `dim_institucion`.
- **Programas / Ofertas Académicas Únicas:** `15.650` programas.
- **Áreas de Conocimiento Canónicas:** `11` áreas (Tecnología, Salud, Administración, etc.).
- **Registros Huérfanos en Claves Foráneas:** `0` (100% de Integridad Referencial).
- **Puntaje Grupal Obtenido en Hito 2:** `10.0 / 10.0` Puntos.

(Con esta guía en mente, el equipo tiene el dominio técnico total del proyecto para asegurar la nota máxima en la presentación de mañana).